Предсказание возраста по фото лица
Отчет по вехе 1

Баранцов Данил, Костырин Николай

23 февраля 2026 г.

1 Выбор метрик качества

Задача - регрессия по возрасту (в годах). Поэтому базовые метрики должны измерять ошибку в годах и быть интерпретируемыми.
Основные метрики:

Метрика	Формула
MAE	$\frac{1}{n}\sum_{i=1}^{n}\lvert y_i - \hat{y}_i\rvert$
RMSE	$\sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$
Acc@k	$\frac{1}{n}\sum_{i=1}^{n}\mathbb{I}[\lvert y_i - \hat{y}_i\rvert \leq k]$

Таблица 1: Формулы метрик

MAE выбрана основной: она отвечает на вопрос «на сколько лет в среднем ошибаемся» и менее чувствительна к выбросам. RMSE добавлена для контроля редких, но больших промахов. Acc@5 и Acc@10 дают прикладную интерпретацию (ошибка в пределах 5/10 лет). Метрики считаем как в целом, так и отдельно по age bins.

2 Первичный анализ данных (EDA)

Датасет: UTKFace.
Признаки (age, gender, race) извлекаются из имени файла формата `age_sex_race_date.jpg`.
Найдено 9 780 файлов; 2 файла не совпали с ожидаемым шаблоном имени. После парсинга и фильтрации возраста (0..116) осталось 9 778 изображений с корректными лейблами.

Count	min	Q1	median	Q3	max	mean	std
9778	1	7	25	48	110	29.2	24.78

Таблица 2: Сводные статистики по возрасту

Рассмотрим распределение возрастов, а также разобьем их на доли, чтобы посмотреть процентную составляющую.
Заметно явное смещение в сторону младших возрастов, а также длиный хвост распределения.

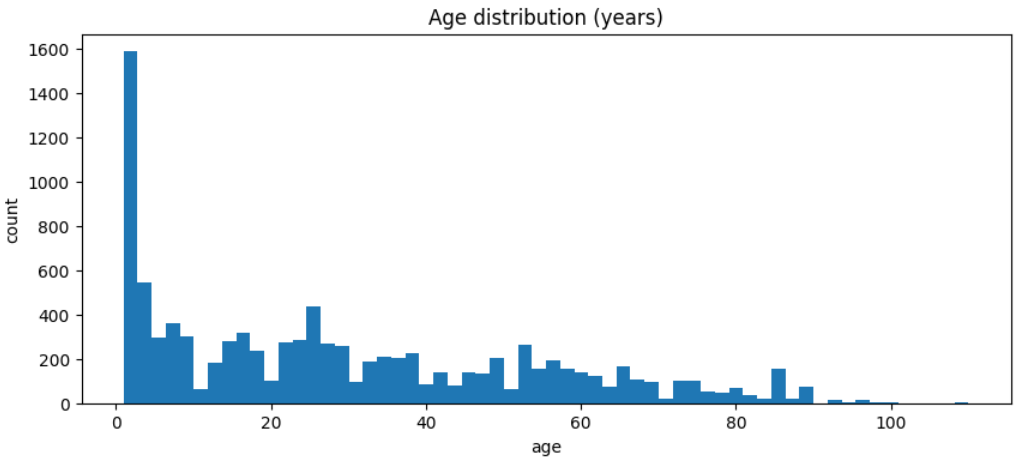

Рис. 1: Распределение возраста

Age-bin	Кол-во	Доля, %
0-2	1587	16.2
3-12	1668	17.1
13-19	909	9.3
20-29	1517	15.5
30-39	1034	10.6
40-49	675	6.9
50-59	938	9.6
60-69	654	6.7
70-79	379	3.9
80+	417	4.3

Таблица 3: Распределение респондентов по возрастным группам

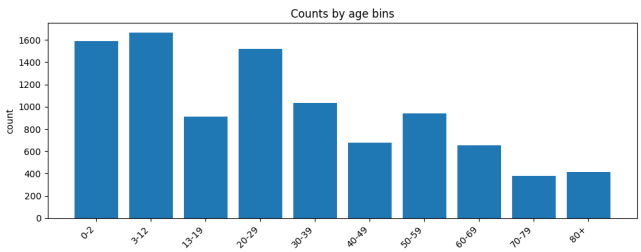

Рис. 2: Процентное распределение количества людей по возрастным группам

2.1 Состав данных по Gender/Race

Распределение по полу и расе важно для контроля возможной систематической ошибки модели и сравнения качества между подгруппами.

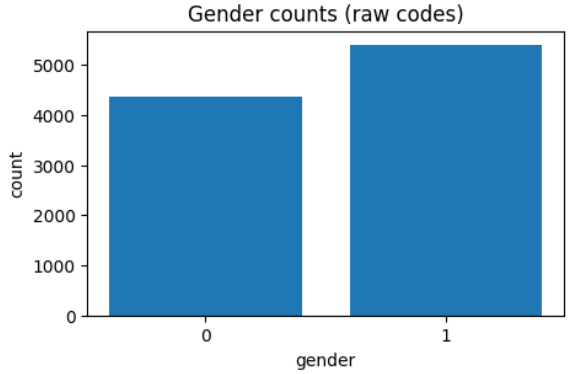

Рис. 3: Распределение людей по полу

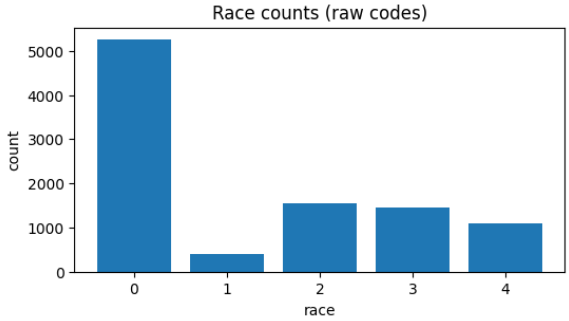

Рис. 4: Распределение людей по расе

Gender	Кол-во	Доля, %
0	4372	44.7
1	5406	55.3

Рис. 5: Распределение людей по полу

Race	Кол-во	Доля, %
0	5265	53.8
1	405	4.1
2	1553	15.9
3	1452	14.8
4	1103	11.3

Рис. 6: Распределение людей по расе

Рассмотрим также взаимосвязь возраста и пола:

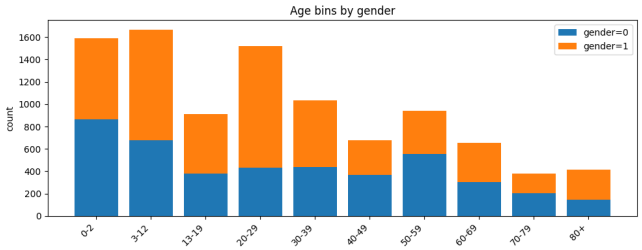

Рис. 7: Совместное распределение пола и возраста

2.2 Визуальная проверка выборки

Для быстрого контроля качества полезно просмотреть примеры из каждой возрастной группы: можно заметить шум (размытые/частично закрытые лица), артефакты обрезания фото и потенциально ошибочные примеры.

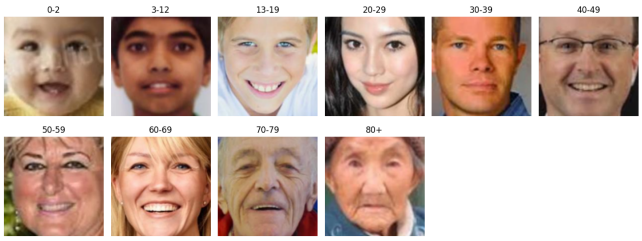

Рис. 8: Примеры изображений по возрастрным группам

2.3 Проблемы и рекомендации

Хочется отметить следующие проблемы:

1. Наш набор данных имеет небольшой дисбаланс классов: количество изображений мужчин выше, чем женщин — примерно 55% мужчин и 45% женщин. Хотя этот дисбаланс недостаточно существенен, чтобы значительно повлиять на точность модели, его стоит отметить для полного понимания смещения набора данных в сторону мужских изображений.

2. Анализ распределения возрастов выявляет два заметных пика в распределении нашего набора данных. Первый кластер охватывает возраст от 0 до примерно 12 лет, в то время как второй охватывает возраст от 16 до 45 лет. Заметно, что эти пики имеют различную интенсивность, причем первый пик значительно сильнее (В частности, распределение является многомодальным).

Рекомендации по решению проблем:

> Внутренний перекос действительно может повлиять на точность нашей модели, поскольку она будет лучше обучаться и обобщать на основе обилия данных о молодых демографических группах, потенциально упуская закономерности или нюансы, распространенные в старших возрастных группах. Устранение этого перекоса становится ключевым моментом для обеспечения справедливого и всестороннего обучения модели в различных возрастных категориях.